

刘佳辉

☎ 16631907622 · ✉ 37220232203748@stu.xmu.edu.cn · 🌐 TMSDMAP ·

教育背景

厦门大学, 计算机科学与技术, 本科

2023.9 - 2027.6

- **学业表现:** 专业 GPA 3.7664/4.0, 排名 10/145(6.9%)
- **主修课程:** 高等数学 (96)、C 语言程序设计、面向对象程序设计 (C++、Java)、数据结构 (95)、算法设计与分析、模式识别 (89)、数据科学与数学建模、计算机组成原理、计算机网络 (90)、UNIX 系统程序设计 (95)

项目经历

集群推理分布式分级内存池化 | AI Infra | 成员

2025.1 – 2026.5

- **项目简介:** 该项目基于 vLLM 框架实现大模型集群推理场景下的分级内存池系统, 通过 CXL 用户态零拷贝访问构建 HBM-DRAM-SSD 三级异构存储架构, 缓解长文本推理过程中 KV Cache 对显存容量的高占用问题。系统集成 CacheBlend 离散缓存复用机制与前缀感知动态驱逐算法, 并结合自研 CUDA 算子优化, 在降低首字延迟的同时提升推理吞吐量与系统扩展性。
- **个人贡献:**
 - 深入复现 CacheBlend 核心机制, 完成长序列切块、全局哈希检索与缓存偏差测算等关键模块, 实现跨请求 KV Cache 的细粒度复用, 减少重复计算开销, 大幅降低模型推理阶段首字延迟。
 - 开发底层 CUDA 算子扩展模块 `extension-cpp`, 通过 Pybind11 完成 C++/CUDA 与 Python 推理框架的绑定, 将核心计算逻辑下沉至底层执行, 减少框架调度冗余, 提升硬件并行利用率与端到端推理效率。
 - 负责 LMCache 性能基准测试, 自主构建测试工具链, 围绕序列长度、缓存命中率、并发规模等指标完成 10W+ 级跑测, 并结构化汇总分析数据, 为后续系统迭代与性能优化提供支撑。

面向专利检索的多视图对比学习表征模型研究 | NLP / 语义检索 | 主要负责人 2025.09 – 至今

- **项目简介:** 该项目面向专利长文本语义检索场景, 围绕专利文本结构复杂、语义粒度多样、候选池规模大与负样本质量不稳定等问题, 构建多视图对比学习表征模型。项目基于 Qwen3-Embedding-4B 进行全参微调, 结合 BM25s、IPC 主分类约束与流式难负例挖掘机制, 提升专利 TopK 检索中的语义匹配能力与排序质量。
- **个人贡献:**
 - 基于 `ms-swift` 重构对比学习损失函数, 引入 LLaVE 难样本加权与 `stop-gradient` 机制, 缓解长文本表征训练中的表示坍塌与优化不稳定问题。
 - 基于多卡 A800 与 DeepSpeed ZeRO-3 完成 Qwen3-Embedding-4B 全参微调, 设计跨设备特征汇聚方案, 扩大 batch 内全局负样本规模, 提升对比学习训练效率与表征区分能力。
 - 结合 BM25s 与 IPC 主分类约束开发流式难负例挖掘 Pipeline, 构建 10 万级多视图训练样本, 提升样本语义区分度与任务适配性。
 - 在 45 万级候选池评测中, 4 个随机种子下相对基座模型 MeanRank 改善 11.58%, MRR/MAP/NDCG 分别提升 2.65%/3.17%/2.02%, Hit@1 提升 4.65%。

获奖经历

- 第十七届蓝桥杯全国软件和信息技术专业人才大赛 | 个人 | 省一等奖
- 第十六届全国大学生数学竞赛 | 个人 | 省一等奖
- 第三十四届高校社杯全国大学生数学建模竞赛 | 编程手 | 省二等奖
- 第四十次 CCF CSP 认证 | 个人 | 290 分 | 排名前 4.33%
- 第十届华为 ICT 大赛网络赛道 | 团队 | 省二等奖; 国家励志奖学金、三好学生、学业优秀奖学金

技术能力

- **编程语言:** 熟练掌握 Python、C/C++, 了解 Java, 具备模型训练、数据处理与工程开发能力。
- **算法基础:** 熟悉数据结构、常用算法、深度学习、NLP、对比学习与语义检索, 具备较强数学建模能力。
- **大模型工程:** 熟悉 PyTorch、ms-swift、DeepSpeed、vLLM、LMCache, 具备多卡训练、模型微调与性能测试经验; 目前关注语音推理与 Omni 全模态大模型。
- **语言能力:** CET4 593, CET6 527, 可熟练阅读英文论文及技术文档。